# Alink漫谈(四):模型的来龙去脉

### 目录

- Alink漫谈(四):模型的来龙去脉
  - o 0x00 摘要
  - o 0x01 模型
    - o <u>1.1 模型包含内容</u>
    - 1.2 Alink的模型文件
  - o 0x02 流程图
  - 0x03 生成模型
    - o 3.1 生成模型
    - o 3.2 转换DataSet
    - o 3.3 存储为Table
  - 0x04 存储模型
    - o 4.1 存储代码
  - 0x05 读取模型
  - o 0x06 预测
    - 6.1 生成runtime rapper
    - 6.2 加载模型
    - o <u>6.3 预测</u>
  - o 0x07 流式预测
  - o 0x08 总结

### 0x00 摘要

Alink 是阿里巴巴基于实时计算引擎 Flink 研发的新一代机器学习算法平台,是业界首个同时支持批式算法、流式算法的机器学习平台。本文将从模型角度入手带领大家来再次深入Alink。

因为Alink的公开资料太少,所以以下均为自行揣测,肯定会有疏漏错误,希望大家指出,我会随时更新。

## 0x01 模型

之前的文章中,我们一直没有仔细说明Alink的模型,本篇我们就深入探究一下。套用下范伟的话:我既想知道模型是怎么来的,我又想知道模型是怎么没的。

### 1.1 模型包含内容

我们先想想,一个机器学习训练出来的模型,应该包含哪些内容。

- 流水线: 因为一个模型可能包括多个阶段, 比如转化, 预测等, 这样构成了一个流水线。
- 算法: 这个是具体机器学习平台绑定的。比如在Flink就是某一个java算法类。
- 参数: 这个是肯定要有的, 机器学习很大一部分工作不就是做这个的嘛。
- 数据:这个其实也应该算参数的一种,也是训练出来的。比如说KMeans算法训练出来的各个中心点。

### 1.2 Alink的模型文件

让我们打开Alink的模型文件来验证下:

### 我们看到了两个类名字:

com.alibaba.alink.pipeline.dataproc.vector.VectorAssembler

com.alibaba.alink.pipeline.clustering.KMeansModel

这就是我们提到的算法,Alink在执行过程中,可以根据这两个类名字来生成java类。而两个算法类看起来是可以构建成一个流水线。我们也能看到参数和数据。

但是有几个地方很奇怪:

- 1048576, 2097152这些奇怪的数字是什么意思?
- 为什么文件的第一个数值是-1? 然后第二行第一个数字是 1? 怎么没有 中间的 0?
- 具体Alink是如何生成和加载模型的?

下面我们就一一排查。

# 0x02 流程图

我们首先给出一个流程图便于大家理解。这个图只是逻辑上的大致概念,和真实运行有区别。因为实际场景上是先 生成执行计划,再具体操作。

```
* 下面只是逻辑上的大致概念,和真实运行有区别,因为实际场景上是先生成执行计划,再具体操作.

* 所以只是给大家一个概念。

* 

* 
* 
Pipeline.fit 训练

* 
+----> KMeansTrainModelData [ centroids, params -- 中心点数据,参数]

* 
----> KMeansOutputModel.calc()中执行,生成中心点数据和参数

* 
| 
* 
+----> Tuple2<Params, Iterable<String>> [ "Params"是模型元数据, Iterable<String>是模型具体数据 ]

* 
----> Tuple2<Params, Iterable<String>> [ "Params"是模型元数据, Iterable<String>是模型具体数据 ]

* 
-----> Collector<Row> [ Row可以有任意的field, 基于position(zero-based)访问field ]

* 
-----> Collector<Row> [ Row可以有任意的field, 基于position(zero-based)访问field ]

* 
-----> Collector<Row> [ Row可以有任意的field, 基于position(zero-based)访问field ]
```

```
+----> List<Row> model [ collector.getRows() ]
             // List<Row> model = completeResult.calc(context);
        +----> DataSet<Row> [ 序列化算子计算结果 ]
              // BaseComQueue.exec --- serializeModel(clearObjs(loopEnd))
        +----> Table output [ AlgoOperator.output, 就是算子组件的输出表 ]
              // KMeansTrainBatchOp.linkFrom --- setOutput
        +----> KMeansModel [ 模型, Find the closest cluster center for every point ]
               // createModel(train(input).getOutputTable()) 这里设定模型参数
               // KMeansModel.setModelData(Table modelData) 这里设定模型数据
        +----> TransformerBase[] [ PipelineModel.transformers ]
              // 这就是最终训练出来的流水线模型,KMeansModel是其中一个,KMeansModelMapper是KMeansMod
el的业务组件
        -1
   PipelineModel.save 存储
        +----> BatchOperator [ 把transformers数组压缩成BatchOperator ]
               // ModelExporterUtils.packTransformersArray
        +----> 存储的模型文件 [ csv文件 ]
               // PipelineModel.save --- CsvSinkBatchOp(path)
        PipelineModel.load 加载
        +---> 存储的模型文件 [ csv文件 ]
               // PipelineModel.load --- CsvSourceBatchOp(path)
        +----> KMeansModel [ 模型, Find the closest cluster center for every point ]
               // 依据文件生成模型, (TransformerBase) clazz.getConstructor(Params.class)
               // 设置数据((ModelBase) transformers[i]).setModelData(data.getOutputTable())
        +----> TransformerBase[] [ 从csv文件读取并恢复的transformers ]
               // ModelExporterUtils.unpackTransformersArray(batchOp)
        +----> PipelineModel [ 流水线模型 ]
               // new PipelineModel(ModelExporterUtils.unpackTransformersArray(batchOp));
   PipelineModel.transform(data) 预测
        +----> ModelSource [ Load model data from ModelSource when open() ]
        // ModelMapperAdapter.open --- List<Row> modelRows = this.modelSource.getModel
Rows(getRuntimeContext());
        +----> Tuple2<Params, Iterable<String>> [ metaAndData ]
```

### 0x03 生成模型

我们还是用KMeans算法来做示例,看看模型数据是什么样子,如何转换成Alink需要的样子。

```
VectorAssembler va = new VectorAssembler()
    .setSelectedCols(new String[]{"sepal_length", "sepal_width", "petal_length", "petal_width"}
)
    .setOutputCol("features");

KMeans kMeans = new KMeans().setVectorCol("features").setK(3)
    .setPredictionCol("prediction_result")
    .setPredictionDetailCol("prediction_detail")
    .setReservedCols("category")
    .setMaxIter(100);

Pipeline pipeline = new Pipeline().add(va).add(kMeans);
pipeline.fit(data);
```

从之前文章中大家可以知道,KMeans训练最重要的类是KMeansTrainBatchOp。KMeansTrainBatchOp在算法迭代结束时候,使用

```
.closeWith(new KMeansOutputModel(distanceType, vectorColName, latitudeColName,
longitudeColName))
```

来输出模型。

### 3.1 生成模型

所以我们重点就要看 KMeansOutputModel 类。其calc函数的作用就是把中心点和参数转化为模型。

• 首先是调用serializeModel将中心点序列化成json。这里记做 (1), 下面代码注释会对应指出。

- 其次save函数会进行序列化,生成了一个Tuple2 < Params, Iterable >。Params是参数,Iterable是模型的具体数据,就是中心点的集合。这里记做 (2),下面代码注释会对应指出。
- 然后save函数把参数和数据分开存储。这里记做 (3), 下面注释会对应指出。
- 最后collector就是模型数据。这里记做 (4), 下面注释会对应指出。

```
/**
 * Tranform the centroids to KmeansModel.
public class KMeansOutputModel extends CompleteResultFunction {
  private DistanceType distanceType;
  private String vectorColName;
   private String latitudeColName;
  private String longtitudeColName;
   @Override
        public List <Row> calc(ComContext context) {
                       KMeansTrainModelData modelData = new KMeansTrainModelData();
      ... 各种赋值操作
                       modelData.params = new KMeansTrainModelData.ParamSummary();
                       modelData.params.k = k;
                       modelData.params.vectorColName = vectorColName;
// 我们可以看出来,在此处,计算出来的中心点和各种参数已经被添加到KMeansTrainModelData之中。
modelData = {KMeansTrainModelData@11319}
 centroids = {ArrayList@11327} size = 3
 0 = {KMeansTrainModelData$ClusterSummary@11330}
  clusterId = 0
   weight = 38.0
  vec = {DenseVector@11333} "6.8499999999999999 3.0736842105263156 5.742105263157895 2.07105263
  1 = {KMeansTrainModelData$ClusterSummary@11331}
 2 = {KMeansTrainModelData$ClusterSummary@11332}
params = {KMeansTrainModelData$ParamSummary@11328}
 k = 3
 vectorSize = 4
 distanceType = {DistanceType@11287} "EUCLIDEAN"
 vectorColName = "features"
  latitudeColName = null
 longtitudeColName = null
                       RowCollector collector = new RowCollector();
      // save函数中将进行(1)(2)(3),后续代码中会具体给出(1)(2)(3)的位置
                       new KMeansModelDataConverter().save(modelData, collector);
     // KMeansModelDataConverter实现了SimpleModelDataConverter, 所以save就调用到了KMeansModelDataCo
nverter.save, 其调用serializeModel将中心点转换jason。最后生成了一个Tuple2 <Params, Iterable<String>>
    // (4) 这时候collector就是模型数据。
                       return collector.getRows();
// 我们能看出来,模型数据已经和模型文件的内容有几分相似了。里面有之前提到的奇怪数字。
collector = {RowCollector@11321}
rows = {ArrayList@11866} size = 4
  0 = {Row@11737} "0,{"vectorCol":"\"features\"","latitudeCol":null,"longitudeCol":null,"distan
ceType":"\"EUCLIDEAN\"", "k":"3", "vectorSize":"4"}"
 1 = {Row@11801} "1048576, {"clusterId":0, "weight":38.0, "vec":{"data":[6.8499999999999999,3.0736
842105263156, 5.742105263157895, 2.071052631578947] } "
 2 = {Row@11868} "2097152, {"clusterId":1, "weight":50.0, "vec": {"data":[5.006,3.417999999999999
,1.4640000000000002,0.24400000000000002]}}"
```

```
3 = {Row@11869} "3145728,{"clusterId":2,"weight":62.0,"vec":{"data":[5.901612903225806,2.7483
870967741937,4.393548387096773,1.4338709677419355]}}"
}
```

# 具体转化是在KMeansModelDataConverter和其基类SimpleModelDataConverter中完成。首先是调用 serializeModel将中心点序列化成json,形成了一个json列表。

```
/**
* KMeans Model.
 * Save the id, center point and point number of clusters.
public class KMeansModelDataConverter extends SimpleModelDataConverter<KMeansTrainModelData, KM</pre>
eansPredictModelData> {
  public KMeansModelDataConverter() {}
   @Override
   public Tuple2<Params, Iterable<String>> serializeModel(KMeansTrainModelData modelData) {
     List <String> data = new ArrayList <>();
      for (ClusterSummary centroid : modelData.centroids) {
         data.add(JsonConverter.toJson(centroid)); // (1), 把中心点转换生成json
     return Tuple2.of(modelData.params.toParams(), data);
   }
   @Override
   public KMeansPredictModelData deserializeModel(Params params, Iterable<String> data) {
     KMeansTrainModelData trainModelData = KMeansUtil.loadModelForTrain(params, data);
      return KMeansUtil.transformTrainDataToPredictData(trainModelData);
   }
```

### 其次进行序列化操作,生成Tuple2<Params, Iterable>。

```
* The abstract class for a kind of {@link ModelDataConverter} where the model data can seriali
* "Tuple2&jt;Params, Iterable&jt;String>>". Here "Params" is the meta data of the model,
and "Iterable&jt; String>" is
 * concrete data of the model.
 */
public abstract class SimpleModelDataConverter<M1, M2> implements ModelDataConverter<M1, M2> {
   public M2 load(List<Row> rows) {
        Tuple2<Params, Iterable<String>> metaAndData = ModelConverterUtils.extractModelMetaAndD
ata(rows);
       return deserializeModel(metaAndData.f0, metaAndData.f1);
    @Override
    public void save(M1 modelData, Collector<Row> collector) {
// (2), 序列化生成Tuple2
        Tuple2<Params, Iterable<String>> model = serializeModel(modelData);
// 此时模型数据是一个元祖Tuple2<Params, Iterable<String>>
model = {Tuple2@11504} "(Params {vectorCol="features", latitudeCol=null, longitudeCol=null, dis
tanceType="EUCLIDEAN", k=3, vectorSize=4},[{"clusterId":0,"weight":38.0,"vec":{"data":[6.849999]
999999999,3.0736842105263156,5.742105263157895,2.071052631578947]}}, {"clusterId":1,"weight":50
.0, "vec": {"data": [5.006, 3.41799999999997, 1.464000000000002, 0.2440000000000002]}}, {"cluster
```

### 然后分开存储参数和数据。

```
/**

* Collector of Row type data.

*/
public class RowCollector implements Collector<Row> {
    private List<Row> rows;
        @Override
        public void collect(Row row) {
            rows.add(row); // 把数据存储起来
        }
}
// 调用栈是
collect:37, RowCollector (com.alibaba.alink.common.utils)
collect:12, RowCollector (com.alibaba.alink.common.utils)
appendStringData:270, ModelConverterUtils (com.alibaba.alink.common.model)
appendMetaRow:35, ModelConverterUtils (com.alibaba.alink.common.model)
save:57, SimpleModelDataConverter (com.alibaba.alink.common.model)
calc:76, KMeansOutputModel (com.alibaba.alink.operator.common.clustering.kmeans)
mapPartition:287, BaseComQueue$4 (com.alibaba.alink.common.comqueue)
```

### 3.2 转换DataSet

模型数据是要转换成 DataSet,即 a collection of rows。其转换目的是为了让模型数据在Alink中更好的传输和被利用。

把模型数据中的string转换为 row数据的时候,可能会遇到string过长的问题,所以Alink就将String分割转存为多行row。这时候就用ModelConverterUtils的getModelId,getStringIndex函数来分割。

这时候得到的model Id就是计算出来的1048576、就是模型文件中的那个奇怪数字。

后续load模型时候也会用同样思路从row转换回模型string。

```
// A utility class for converting model data to a collection of rows.
class ModelConverterUtils {
    /**
    * Maximum number of slices a string can split to.
    */
    static final long MAX_NUM_SLICES = 1024L * 1024L;

private static long getModelId(int stringIndex, int sliceIndex) {
    return MAX_NUM_SLICES * stringIndex + sliceIndex;
    }

private static int getStringIndex(long modelId) {
    return (int) ((modelId) / MAX_NUM_SLICES);
    }
}

row = {Row@11714} "1048576,{"clusterId":0,"weight":62.0,"vec":{"data":[5.901612903225806,2.7483 870967741932,4.393548387096773,1.4338709677419355]}}"
```

```
fields = {Object[2]@11724}
    0 = {Long@11725} 1048576
    1 = "{"clusterId":0,"weight":62.0,"vec":{"data":[5.901612903225806,2.7483870967741932,4.39354
8387096773,1.4338709677419355]}}"

// 相关调用栈如下
appendStringData:270, ModelConverterUtils (com.alibaba.alink.common.model)
appendDataRows:52, ModelConverterUtils (com.alibaba.alink.common.model)
save:58, SimpleModelDataConverter (com.alibaba.alink.common.model)
calc:76, KMeansOutputModel (com.alibaba.alink.operator.common.clustering.kmeans)
mapPartition:287, BaseComQueue$4 (com.alibaba.alink.common.comqueue)
run:103, MapPartitionDriver (org.apache.flink.runtime.operators)
...
run:748, Thread (java.lang)
```

### 3.3 存储为Table

前面KMeansOutputModel最终返回的是一个DataSet,这里将把这个DataSet转化为Table存储在流水线中。

```
public final class KMeansTrainBatchOp extends BatchOperator <KMeansTrainBatchOp>
       public KMeansTrainBatchOp linkFrom(BatchOperator <?>... inputs) {
                DataSet <Row> finalCentroid = iterateICQ(initCentroid, data,
                       vectorSize, maxIter, tol, distance, distanceType, vectorColName, null,
null);
    // 这里存储为Table
                this.setOutput(finalCentroid, new KMeansModelDataConverter().getModelSchema());
                return this:
}
this = {KMeansTrainBatchOp@5130} "UnnamedTable$1"
params = {Params@5143} "Params {vectorCol="features", maxIter=100, reservedCols=["category"],
k=3, predictionCol="prediction result", predictionDetailCol="prediction detail"}"
output = {TableImpl@5188} "UnnamedTable$1"
 tableEnvironment = {BatchTableEnvironmentImpl@5190}
 operationTree = {DataSetQueryOperation@5191}
 operationTreeBuilder = {OperationTreeBuilder@5192}
 lookupResolver = {LookupCallResolver@5193}
 tableName = "UnnamedTable$1"
 sideOutputs = null
```

我们可以看到,在Alink运行时候,模型数据都统一转化为Table类型。这部分原因可能是因为Alink想要统一处理DataSet和DataStream,即批和流都要用一个思路或者代码来处理。而Flink目前已经用Table来统一整合二者,所以Alink就针对此统一用Table。参见如下:

```
public abstract class ModelBase<M extends ModelBase<M>> extends TransformerBase<M>
    implements Model<M> {
        protected Table modelData;
}

public abstract class AlgoOperator<T extends AlgoOperator<T>>
        implements WithParams<T>, HasMLEnvironmentId<T>, Serializable {
        // Params for algorithms.
        private Params params;

        // The table held by operator.
        private Table output = null;
```

```
// The side outputs of operator that be similar to the stream's side outputs.
private Table[] sideOutputs = null;
}
```

### 0x04 存储模型

### 4.1 存储代码

我们修改一下代码,调用save函数把流水线模型存储起来。Alink目前是把模型文件存储成特殊格式的csv文件。

```
Pipeline pipeline = new Pipeline().add(va).add(kMeans);
pipeline.fit(data).save("./kmeans.csv");
```

#### 流水线存储代码如下:

```
public class PipelineModel extends ModelBase<PipelineModel> implements LocalPredictable {
    // Pack the pipeline model to a BatchOperator.
    public BatchOperator save() {
        return ModelExporterUtils.packTransformersArray(transformers);
    }
}
```

我们可以看到,流水线最终调用到 ModelExporterUtils.packTransformersArray,所以我们就重点看看这个函数。这里可以解答模型文件中的问题:<u>为什么第一个数值是-1?然后是 1?怎么没有 中间的 0 ?</u>

模型文件中每行第一个数字对应的是transformer的index。config是特殊的所以index设置为-1,下面代码中有指出。

模型文件中的1 就是说明第二个transformer KMeansModel具有数据,具体数据内容就在index 1对应这行。

为什么模型文件没有 0 就是因为第一个transformer VectorAssembler没有自己的数据,所以就不包括了。

```
class ModelExporterUtils {
    //Pack an array of transformers to a BatchOperator.
   static BatchOperator packTransformersArray(TransformerBase[] transformers) {
       int numTransformers = transformers.length;
       String[] clazzNames = new String[numTransformers];
       String[] params = new String[numTransformers];
       String[] schemas = new String[numTransformers];
        for (int i = 0; i < numTransformers; i++) {</pre>
            clazzNames[i] = transformers[i].getClass().getCanonicalName();
            params[i] = transformers[i].getParams().toJson();
            schemas[i] = "";
            if (transformers[i] instanceof PipelineModel) {
                schemas[i] = CsvUtil.schema2SchemaStr(PIPELINE MODEL SCHEMA);
            } else if (transformers[i] instanceof ModelBase) {
                long envId = transformers[i].getMLEnvironmentId();
                BatchOperator data = BatchOperator.fromTable(((ModelBase) transformers[i]).getM
odelData());
                data.setMLEnvironmentId(envId);
                data = data.link(new VectorSerializeBatchOp().setMLEnvironmentId(envId));
                schemas[i] = CsvUtil.schema2SchemaStr(data.getSchema());
       Map<String, Object> config = new HashMap<>();
       config.put("clazz", clazzNames);
       config.put("param", params);
       config.put("schema", schemas);
        // 这里就对应着模型文件的第一个数值 -1, 就是config对应的index就是-1。
       Row row = Row.of(-1L, JsonConverter.toJson(config));
```

```
// 这个时候我们可以看到, schema, param, clazz 就是对应着模型文件中的输出, 我们距离目标更近了一步
 config = \{HashMap@5432\} size = 3
 "schema" -> {String[2]@5431}
 key = "schema"
 value = \{String[2]@5431\}
  0 = ""
  1 = "model_id BIGINT, model_info VARCHAR"
 "param" -> {String[2]@5430}
 key = "param"
 value = \{String[2]@5430\}
   0 = "{"outputCol":"\"features\"","selectedCols":"[\"sepal length\",\"sepal width\",\"petal l
ength\",\"petal width\"]"}"
  1 = "{"vectorCol":"\"features\"","maxIter":"100","reservedCols":"[\"category\"]","k":"3","pr
edictionCol":"\"prediction result\"", "predictionDetailCol":"\"prediction detail\""}"
 "clazz" -> {String[2]@5429}
 key = "clazz"
 value = \{String[2]@5429\}
  0 = "com.alibaba.alink.pipeline.dataproc.vector.VectorAssembler"
  1 = "com.alibaba.alink.pipeline.clustering.KMeansModel"
       BatchOperator packed = new MemSourceBatchOp(Collections.singletonList(row), PIPELINE MO
DEL SCHEMA)
            .setMLEnvironmentId(transformers.length > 0 ? transformers[0].getMLEnvironmentId()
               MLEnvironmentFactory.DEFAULT ML ENVIRONMENT ID);
       for (int i = 0; i < numTransformers; i++) {</pre>
           BatchOperator data = null;
           final long envId = transformers[i].getMLEnvironmentId();
           if (transformers[i] instanceof PipelineModel) {
               data = packTransformersArray(((PipelineModel) transformers[i]).transformers);
           } else if (transformers[i] instanceof ModelBase) {
               data = BatchOperator.fromTable(((ModelBase) transformers[i]).getModelData())
                    .setMLEnvironmentId(envId);
               data = data.link(new VectorSerializeBatchOp().setMLEnvironmentId(envId));
            if (data != null) {
               // 这对应模型文件中的1,为什么模型文件没有 O就是因为VectorAssembler没有自己的数据,所以就
不包括了。
               packed = new UnionAllBatchOp().setMLEnvironmentId(envId).linkFrom(packed, packB
atchOp(data, i));
       return packed;
```

# 0x05 读取模型

下面代码作用是: 读取模型, 然后进行转换。

```
BatchOperator data = new CsvSourceBatchOp().setFilePath(URL).setSchemaStr(SCHEMA_STR);
PipelineModel pipeline = PipelineModel.load("./kmeans.csv");
pipeline.transform(data).print();
```

### 读取模型文件、然后转换成PipelineModel。

```
public class PipelineModel extends ModelBase<PipelineModel> implements LocalPredictable {
    //Load the pipeline model from a path.
```

```
public static PipelineModel load(String path) {
        return load(new CsvSourceBatchOp(path, PIPELINE MODEL SCHEMA));
    //Load the pipeline model from a BatchOperator.
    public static PipelineModel load(BatchOperator batchOp) {
        return new PipelineModel(ModelExporterUtils.unpackTransformersArray(batchOp));
    public PipelineModel(TransformerBase[] transformers) {
        super(null);
        if (null == transformers) {
            this.transformers = new TransformerBase[]{};
        } else {
            List<TransformerBase> flattened = new ArrayList<>();
            flattenTransformers(transformers, flattened);
            this.transformers = flattened.toArray(new TransformerBase[0]);
    }
// 相关调用栈如下
unpackTransformersArray:91, ModelExporterUtils (com.alibaba.alink.pipeline)
load:149, PipelineModel (com.alibaba.alink.pipeline)
load:142, PipelineModel (com.alibaba.alink.pipeline)
main:22, KMeansExample2 (com.alibaba.alink)
```

以下是为导入导出用到的功能类,比如导入导出transformer。我们能够看到大致功能如下:

- 从index为-1处获取配置信息。
- 从配置信息中获取了算法类,参数, shema等信息。
- 根据算法类,生成所有transformer。
- 每次生成一个新transformer时候,会读取文件中对应行内容,unpack该行内容,生成模型对应的数据,然后赋值给transformer。注意的是,解析出来的数据被包装成一个BatchOperator。

```
class ModelExporterUtils {
    // Unpack transformers array from a BatchOperator.
    static TransformerBase[] unpackTransformersArray(BatchOperator batchOp) {
       String configStr;
       try {
            // 从index为-1处获取配置信息。
           List<Row> rows = batchOp.as(new String[]{"f1", "f2"}).where("f1=-1").collect();
           Preconditions.checkArgument(rows.size() == 1, "Invalid model.");
           configStr = (String) rows.get(0).getField(1);
        } catch (Exception e) {
           throw new RuntimeException ("Fail to collect model config.");
        // 这里从配置信息中获取了算法类,参数,shema等信息
        String[] clazzNames = JsonConverter.fromJson(JsonPath.read(configStr, "$.clazz").toStri
ng(), String[].class);
       String[] params = JsonConverter.fromJson(JsonPath.read(configStr, "$.param").toString()
, String[].class);
        String[] schemas = JsonConverter.fromJson(JsonPath.read(configStr, "$.schema").toString
(), String[].class);
        // 遍历,生成所有transformer。
       int numTransformers = clazzNames.length;
       TransformerBase[] transformers = new TransformerBase[numTransformers];
        for (int i = 0; i < numTransformers; i++) {</pre>
           try {
```

```
Class clazz = Class.forName(clazzNames[i]);
                transformers[i] = (TransformerBase) clazz.getConstructor(Params.class).newInsta
nce (
                    Params.fromJson(params[i])
                        .set(HasMLEnvironmentId.ML ENVIRONMENT ID, batchOp.getMLEnvironmentId()
));
            } catch (Exception e) {
                throw new RuntimeException ("Fail to re construct transformer.", e);
            BatchOperator packed = batchOp.as(new String[]{"f1", "f2"}).where("f1=" + i);
            if (transformers[i] instanceof PipelineModel) {
                BatchOperator data = unpackBatchOp(packed, CsvUtil.schemaStr2Schema(schemas[i])
);
                transformers[i] = new PipelineModel(unpackTransformersArray(data))
                    .setMLEnvironmentId(batchOp.getMLEnvironmentId());
            } else if (transformers[i] instanceof ModelBase) {
                BatchOperator data = unpackBatchOp(packed, CsvUtil.schemaStr2Schema(schemas[i])
);
                // 这里会设置模型数据。
                ((ModelBase) transformers[i]).setModelData(data.getOutputTable());
        return transformers;
```

#### 最后生成的transformers如下:

# 0x06 预测

```
pipeline.transform(data).print(); 是预测的代码。
```

### 6.1 生成runtime rapper

预测算法需要被包装成RichMapFunction,才能够被Flink引用。

VectorAssembler是起到转换csv文件作用。KMeansModel是用来预测。预测时候会调用到 KMeansModel.transform,其又会调用到linkFrom,这里生成了runtime rapper。

```
.setMLEnvironmentId(input.getMLEnvironmentId()), input);

}

// this.getModelData()是模型数据,对应linkFrom的输入参数inputs[0]

// input 这个是待处理的数据。,对应linkFrom的输入参数inputs[1]

// 模型数据就是之前从csv中取出来设置的。
public abstract class ModelBase<M extends ModelBase<M>> extends TransformerBase<M>
    implements Model<M> {
    public Table getModelData() {
        return this.modelData;
    }
}
```

ModelMapBatchOp.linkFrom 代码中,会生成ModelMapperAdapter。此时会把模型信息作为广播变量存起来。这样在后续预测时候就可以先load模型数据。

```
public class ModelMapBatchOp<T extends ModelMapBatchOp<T>> extends BatchOperator<T> {
   private static final String BROADCAST_MODEL_TABLE_NAME = "broadcastModelTable";
   // (modelScheme, dataSchema, params) -> ModelMapper
   private final TriFunction<TableSchema, TableSchema, Params, ModelMapper> mapperBuilder;
   public ModelMapBatchOp(TriFunction<TableSchema, TableSchema, Params, ModelMapper> mapperBuil
der, Params params) {
     super(params);
      this.mapperBuilder = mapperBuilder;
  @Override
   public T linkFrom(BatchOperator<?>... inputs) {
         BroadcastVariableModelSource modelSource = new BroadcastVariableModelSource(BROADCAST
MODEL TABLE NAME);
         ModelMapper mapper = this.mapperBuilder.apply(
               inputs[0].getSchema(),
               inputs[1].getSchema(),
               this.getParams());
         DataSet<Row> modelRows = inputs[0].getDataSet().rebalance();
         // 这里会广播变量
         DataSet<Row> resultRows = inputs[1].getDataSet()
               .map(new ModelMapperAdapter(mapper, modelSource))
               .withBroadcastSet(modelRows, BROADCAST MODEL TABLE NAME);
         TableSchema outputSchema = mapper.getOutputSchema();
         this.setOutput(resultRows, outputSchema);
         return (T) this;
   }
```

#### 6.2 加载模型

当预测时候,ModelMapperAdapter会在open函数先加载模型。

```
public class ModelMapperAdapter extends RichMapFunction<Row, Row> implements Serializable {
    @Override
    public void open(Configuration parameters) throws Exception {
        List<Row> modelRows = this.modelSource.getModelRows(getRuntimeContext());
```

```
this.mapper.loadModel(modelRows);
}

// 加载出来的模型数据举例如下

modelRows = {ArrayList@10100} size = 4
0 = {Row@10103} "2097152,{"clusterId":1,"weight":62.0,"vec":{"data":[5.901612903225806,2.7483870967741932,4.393548387096773,1.4338709677419355]}}"
1 = {Row@10104} "0,{"vectorCol":"\"features\"","latitudeCol":null,"longitudeCol":null,"distanceType":"\"EUCLIDEAN\"","k":3","vectorSize":"4"}"
2 = {Row@10105} "3145728,{"clusterId":2,"weight":50.0,"vec":{"data":[5.0059999999999,3.418,1.463999999999997,0.2440000000000002]}}"
3 = {Row@10106} "1048576,{"clusterId":0,"weight":38.0,"vec":{"data":[6.85,3.0736842105263156,5.742105263157894,2.0710526315789477]}}"
```

this.mapper.loadModel(modelRows) 会调用KMeansModelMapper.loadModel, 其最后调用到

- ModelConverterUtils.extractModelMetaAndData 来进行反序列化,把DataSet转换回Tuple。
- 最终调用到KMeansUtil.KMeansTrainModelData生成用来预测的模型KMeansTrainModelData

```
/**
 * The abstract class for a kind of {@link ModelDataConverter} where the model data can seriali
ze to "Tuple2&jt; Params, Iterable&jt; String> > ". Here "Params" is the meta data of the mod
el, and "Iterable&jt;String>" is concrete data of the model.
*/
public abstract class SimpleModelDataConverter<M1, M2> implements ModelDataConverter<M1, M2> {
   @Override
   public M2 load(List<Row> rows) {
       Tuple2<Params, Iterable<String>> metaAndData = ModelConverterUtils.extractModelMetaAndD
ata(rows);
        return deserializeModel(metaAndData.f0, metaAndData.f1);
}
metaAndData = {Tuple2@10267} "(Params {vectorCol="features", latitudeCol=null, longitudeCol=null
1, distanceType="EUCLIDEAN", k=3, vectorSize=4},com.alibaba.alink.common.model.ModelConverterUt
ils$StringDataIterable@7e9c1b42)"
 f0 = {Params@10252} "Params {vectorCol="features", latitudeCol=null, longitudeCol=null, distan
ceType="EUCLIDEAN", k=3, vectorSize=4}"
  params = {HashMap@10273} size = 6
   "vectorCol" -> ""features""
   "latitudeCol" -> null
   "longitudeCol" -> null
   "distanceType" -> ""EUCLIDEAN""
   "k" -> "3"
   "vectorSize" -> "4"
 f1 = {ModelConverterUtils$StringDataIterable@10262}
 iterator = {ModelConverterUtils$StringDataIterator@10272}
  modelRows = {ArrayList@10043} size = 4
   order = {Integer[4]@10388}
   curr = "{"clusterId":0,"weight":38.0,"vec":{"data":[6.85,3.0736842105263156,5.74210526315789
4,2.0710526315789477]}}"
   listPos = 2
```

#### 可以看到getModelRows就是从广播变量中读取数据。

```
public class BroadcastVariableModelSource implements ModelSource {
   public List<Row> getModelRows(RuntimeContext runtimeContext) {
      return runtimeContext.getBroadcastVariable(modelVariableName);
}
```

} }

### 6.3 预测

最后预测是在ModelMapperAdapter的map函数。这实际上是 flink根据用户代码生成的执行计划进行相应处理 后自己执行的。

```
/**
  * Adapt a {@link ModelMapper} to run within flink.
  * 
  * This adapter class hold the target {@link ModelMapper} and it's {@link ModelSource}. Upon op en(),
  * it will load model rows from {@link ModelSource} into {@link ModelMapper}.
  */
public class ModelMapperAdapter extends RichMapFunction<Row, Row> implements Serializable {
    @Override
    public Row map(Row row) throws Exception {
        return this.mapper.map(row);
    }
}
```

mapper实际调用到KMeansModelMapper,这里就用到了模型数据。

```
// Find the closest cluster center for every point.
public class KMeansModelMapper extends ModelMapper {
   @Override
   public Row map(Row row) {
       Vector record = KMeansUtil.getKMeansPredictVector(colIdx, row);
           . . . . . .
           if(isPredDetail){
              double[] probs = KMeansUtil.getProbArrayFromDistanceArray(clusterDistances);
              DenseVector vec = new DenseVector(probs.length);
              for(int i = 0; i < this.modelData.params.k; i++) {</pre>
                  // 这里就用到了模型数据进行预测
                  vec.set((int)this.modelData.getClusterId(i), probs[i]);
              res.add(vec.toString());
     return outputColsHelper.getResultRow(row, Row.of(res.toArray(new Object[0])));
}
// 模型数据如下
this = {KMeansModelMapper@10822}
modelData = {KMeansPredictModelData@10828}
 centroids = {FastDistanceMatrixData@10842}
  05263156,2.7483870967741937\n 1.4639999999997,5.742105263157894,4.393548387096774\n 0.2440
000000000002,2.0710526315789473,1.4338709677419355\n"
  label = {DenseMatrix@10844} "mat[1,3]:\n 38.945592000000005,93.63106648199445,63.7419198751
3008\n"
  rows = {Row[3]@10845}
 params = {KMeansTrainModelData$ParamSummary@10829}
  vectorSize = 4
  distanceType = {DistanceType@10849} "EUCLIDEAN"
  vectorColName = "features"
```

```
latitudeColName = null
longtitudeColName = null
```

### 0x07 流式预测

我们知道Alink是可以支持批式预测和流式预测。我们看看流式预测是怎么处理的。下面就是KMeans的流式预测。

```
public class KMeansExampleStream {
   AlgoOperator getData(boolean isBatch) {
        Row[] array = new Row[] {
                Row.of(0, "0 0 0"),
                Row.of(1, "0.1,0.1,0.1"),
                Row.of(2, "0.2,0.2,0.2"),
                Row.of(3, "9 9 9"),
                Row.of(4, "9.1 9.1 9.1"),
                Row.of(5, "9.2 9.2 9.2")
        };
        if (isBatch) {
            return new MemSourceBatchOp(
                   Arrays.asList(array), new String[] {"id", "vec"});
        } else {
            return new MemSourceStreamOp(
                   Arrays.asList(array), new String[] {"id", "vec"});
        }
    public static void main(String[] args) throws Exception {
        KMeansExampleStream ks = new KMeansExampleStream();
        BatchOperator inOp1 = (BatchOperator)ks.getData(true);
        StreamOperator inOp2 = (StreamOperator)ks.getData(false);
        KMeansTrainBatchOp trainBatch = new KMeansTrainBatchOp().setVectorCol("vec").setK(2);
        KMeansPredictBatchOp predictBatch = new KMeansPredictBatchOp().setPredictionCol("pred")
        trainBatch.linkFrom(inOp1);
        KMeansPredictStreamOp predictStream = new KMeansPredictStreamOp(trainBatch).setPredicti
onCol("pred");
        predictStream.linkFrom(inOp2);
        predictStream.print(-1,5);
        StreamOperator.execute();
```

predictStream.linkFrom 是我们这里的要点,其调用到ModelMapStreamOp。ModelMapStreamOp这个类的代码虽然少,但是条理非常清晰,非常适合学习。

- 首先相关继承关系如下 KMeansPredictStreamOp extends ModelMapStreamOp
- 其次能看出来,流预测所依赖的数据模型依然是一个批处理产生的模型 | BatchOperator model | 。
- mapperBuilder是业务模型算子,其构造是通过(modelScheme, dataSchema, params)得出来的,这 恰恰就是机器学习的几个要素。
- KMeansModelMapper就是具体模型算子: KMeansModelMapper extends ModelMapper 。

```
// Find the closest cluster center for every point.
public final class KMeansPredictStreamOp extends ModelMapStreamOp <KMeansPredictStreamOp>
  implements KMeansPredictParams <KMeansPredictStreamOp> {
```

```
// @param model trained from kMeansBatchOp
public KMeansPredictStreamOp(BatchOperator model) {
    this(model, new Params());
}

public KMeansPredictStreamOp(BatchOperator model, Params params) {
    super(model, KMeansModelMapper::new, params);
}
```

### 具体深入代码, 我们可以看到:

- 首先,把DataSet的数据一次性都取出来,因为都取出来容易造成内存问题,所以 DataSet.collect 注释中有警告: Convenience method to get the elements of a DataSet as a List. As DataSet can contain a lot of data, this method should be used with caution.
- 其次,通过如下代码 this.mapperBuilder.apply(modelSchema, in.getSchema(), this.getParams()); 构建业务模型KMeansModelMapper。
- 然后, new ModelMapperAdapter(mapper, modelSource) 会建立一个 RichFunction 作为运行适配层。
- 最后,输入的流数据源 in 会通过 in.getDataStream().map((new ModelMapperAdapter(mapper, modelSource)); 来完成预测。
- 实际上,这时候只是生成stream graph,具体计算是后续flink会根据graph再进行处理。

```
public class ModelMapStreamOp<T extends ModelMapStreamOp <T>> extends StreamOperator<T> {
       private final BatchOperator model;
        // (modelScheme, dataSchema, params) -> ModelMapper
       private final TriFunction<TableSchema, TableSchema, Params, ModelMapper> mapperBuilder;
       public ModelMapStreamOp(BatchOperator model,
                                                       TriFunction<TableSchema, TableSchema, P
arams, ModelMapper> mapperBuilder,
                                                       Params params) {
               super(params);
               this.model = model;
               this.mapperBuilder = mapperBuilder;
        }
       @Override
        public T linkFrom(StreamOperator<?>... inputs) {
               StreamOperator<?> in = checkAndGetFirst(inputs);
               TableSchema modelSchema = this.model.getSchema();
               trv {
      // 把模型数据全都取出来
                       DataBridge modelDataBridge = DirectReader.collect(model);
                       DataBridgeModelSource modelSource = new DataBridgeModelSource(modelData
Bridge);
                       ModelMapper mapper = this.mapperBuilder.apply(modelSchema, in.getSchema
(), this.getParams());
     // 生成runtime适配层和预测算子。把预测结果返回。
      // 实际上,这时候只是生成stream graph,具体计算是后续flink会根据graph再进行处理。
                       DataStream <Row> resultRows = in.getDataStream().map(new ModelMapperAda
pter(mapper, modelSource));
                       TableSchema resultSchema = mapper.getOutputSchema();
                       this.setOutput(resultRows, resultSchema);
                       return (T) this;
```

### 0x08 总结

现在我们已经梳理了Alink模型的来龙去脉,让我们再次拿出模型文件内容来验证。

- 第一行是元数据信息,其中包含schema, 算法类名称,元参数。Alink可以通过这些信息生成流水线的 transformer。
- 后续行是算法类所需要的模型数据。每一行对应一个算法类。Alink会取出这些数据来设置到transformer中。
- 后续行的模型数据是具体算法相关。
- 第一行特殊之处在于其index是 -1。后续数据行的index从0开始,如果某一个transformer没有数据,则没有对应行,跳过index。

这样Alink就可以根据模型文件生成流水线模型。