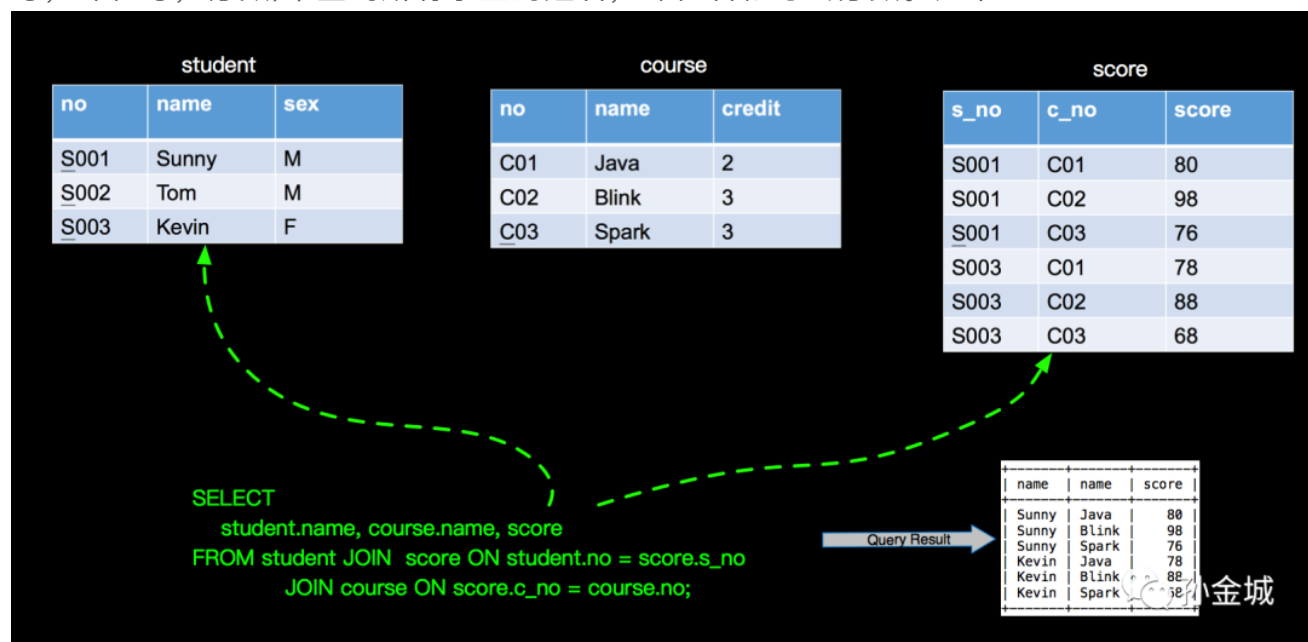


Apache Flink 漫谈系列 - 双流JOIN

什么是JOIN

JOIN的本质是分别从N(N>=1)张表中获取不同的字段，进而得到最完整的记录行。比如我们有一个查询需求：在学生表(学号，姓名，性别)，课程表(课程号，课程名，学分)和成绩表(学号，课程号，分数)中查询所有学生的姓名，课程名和考试分数。如下：



为啥需要JOIN

JOIN的本质是数据拼接，那么如果我们将所有数据列存储在一张大表中，是不是就不需要JOIN了呢？如果真的能将所需的数据都在一张表存储，我想就真的不需要JOIN的算子了，但现实业务中真的能做到将所需数据放到同一张大表里面吗？答案是否定的，核心原因有2个：

- 产生数据的源头可能不是一个系统；
- 产生数据的源头是同一个系统，但是数据冗余的沉重代价，迫使我们遵循数据库范式，进行表的设计。简说NF如下：
 - 1NF - 列不可再分
 - 2NF - 符合1NF，并且非主键属性全部依赖于主键属性
 - 3NF - 符合2NF，并且传递依赖，即：即任何字段不能由其他字段派生出来
 - BCNF - 符合3NF，并且主键属性之间无依赖关系

JOIN的种类

- CROSS JOIN - 交叉连接，计算笛卡儿积
- INNER JOIN - 内连接，返回满足条件的记录
- OUTER JOIN
 - LEFT - 返回左表所有行，右表不存在补NULL；
 - RIGHT - 返回右表所有行，左边不存在补NULL；
 - FULL - 返回左表和右表的并集，不存在一边补NULL；
- SELF JOIN - 自连接，将表查询时候命名不同的别名；

JOIN语法

JOIN 在SQL89和SQL92中有不同的语法，以INNER JOIN为例说明：

- SQL89 - 表之间用“，”逗号分割，链接条件和过滤条件都在Where子句指定

```
SELECT
  a.colA,
  b.colA
FROM
  tab1 AS a , tab2 AS b
WHERE a.id = b.id and a.other > b.other
```

- SQL92

```
SELECT
  a.colA,
  b.colA
FROM
  tab1 AS a JOIN tab2 AS b ON a.id = b.id
WHERE
  a.other > b.other
```

SQL92将链接条件在ON子句指定，过滤条件在WHERE子句指定，逻辑更为清晰，本篇中的后续示例将应用SQL92语法进行SQL的编写。

```
tableExpression [ LEFT|RIGHT|FULL|INNER|SELF ] JOIN tableExpression [ ON jc
```

语义示例说明

我们以开篇示例中的三张表学生表(学号，姓名，性别)，课程表(课程号，课程名，学分)和成绩表(学号，课程号，分数)来介绍各种JOIN的语义。

student			course			score		
no	name	sex	no	name	credit	s_no	c_no	score
S001	Sunny	M	C01	Java	2	S001	C01	80
S002	Tom	M	C02	Blink	3	S001	C02	98
S003	Kevin	F	C03	Spark	3	S001	C03	76
						S003	C01	78
						S003	C02	98
						S003	C03	68

CROSS JOIN

交叉连接会对两个表进行笛卡尔积，也就是LEFT表的每一行和RIGHT表的所有行进行联接，因此生成结果表的行数是两个表行数的乘积，如student和course表的CROSS JOIN结果如下：

```
mysql> SELECT * FROM student JOIN course;
+-----+-----+-----+-----+-----+-----+
| no   | name  | sex  | no   | name  | credit |
+-----+-----+-----+-----+-----+-----+
| S001 | Sunny | M    | C01  | Java  | 2      |
| S002 | Tom   | F    | C01  | Java  | 2      |
| S003 | Kevin | M    | C01  | Java  | 2      |
| S001 | Sunny | M    | C02  | Blink | 3      |
| S002 | Tom   | F    | C02  | Blink | 3      |
| S003 | Kevin | M    | C02  | Blink | 3      |
| S001 | Sunny | M    | C03  | Spark | 3      |
| S002 | Tom   | F    | C03  | Spark | 3      |
| S003 | Kevin | M    | C03  | Spark | 3      |
+-----+-----+-----+-----+-----+-----+
9 rows in set (0.00 sec)
```

如上结果我们得到9行=student(3) x course(3)。交叉联接一般会消耗较大的资源，也被很多用户质疑交叉联接存在的意义？（任何时候我们都有质疑的权利，同时也建议我们养成自己质疑自己“质疑”的习惯，就像小时候不理解父母的“废话”一样）。我们以开篇的示例说明交叉联接的巧妙之处。

开篇中我们的查询需求是：在学生表(学号，姓名，性别)，课程表(课程号，课程名，学分)和成绩表(学号，课程号，分数)中查询所有学生的姓名，课程名和考试分数。开篇中的SQL语句得到的结果如下：

```
mysql> SELECT
->     student.name, course.name, score
-> FROM student JOIN  score ON student.no = score.s_no
->         JOIN course ON score.c_no = course.no;
+-----+-----+-----+
| name  | name  | score |
+-----+-----+-----+
| Sunny | Java  | 80    |
| Sunny | Blink | 98    |
| Sunny | Spark | 76    |
| Kevin | Java  | 78    |
| Kevin | Blink | 88    |
| Kevin | Spark | 68    |
+-----+-----+-----+
6 rows in set (0.00 sec)
```

如上INNER JOIN的结果我们发现少了Tom同学的成绩，原因是Tom同学没有参加考试，在score表中没有Tom的成绩，但是我们可能希望虽然Tom没有参加考试但仍然希望Tom的成绩能够在查询结果中显示(成绩 0 分)，面对这样的需求，我们怎么处理呢？交叉联接可以帮助我们：

- 第一步 student和course 进行交叉联接：

```
mysql> SELECT
->     stu.no, c.no, stu.name, c.name
-> FROM student stu JOIN course c 笛卡尔积
-> ORDER BY stu.no; -- 排序只是方便大家查看:)
```

no	no	name	name
S001	C03	Sunny	Spark
S001	C01	Sunny	Java
S001	C02	Sunny	Blink
S002	C03	Tom	Spark
S002	C01	Tom	Java
S002	C02	Tom	Blink
S003	C02	Kevin	Blink
S003	C03	Kevin	Spark
S003	C01	Kevin	Java

9 rows in set (0.00 sec)

- 第二步 将交叉联接的结果与score表进行左外联接，如下：

```
mysql> SELECT
->     stu.no, c.no, stu.name, c.name,
->     CASE
->         WHEN s.score IS NULL THEN 0
->         ELSE s.score
->     END AS score
-> FROM student stu JOIN course c  -- 迪卡尔积
-> LEFT JOIN score s ON stu.no = s.s_no and c.no = s.c_no -- LEFT OUTER
-> ORDER BY stu.no; -- 排序只是为了大家好看一点:)
```

no	no	name	name	score
S001	C03	Sunny	Spark	76
S001	C01	Sunny	Java	80
S001	C02	Sunny	Blink	98
S002	C02	Tom	Blink	0
S002	C03	Tom	Spark	0
S002	C01	Tom	Java	0
S003	C02	Kevin	Blink	88
S003	C03	Kevin	Spark	68
S003	C01	Kevin	Java	78

-- TOM 虽然没有参加考试，但是仍然看到他的信

```
9 rows in set (0.00 sec)
```

INNER JOIN

内联接在SQL92中 ON 表示联接添加，可选的WHERE子句表示过滤条件，如开篇的示例就是一个多表的内联接，我们在看一个简单的示例: 查询成绩大于80分的学生学号，学生姓名和成绩:

```
mysql> SELECT
-> stu.no, stu.name , s.score
-> FROM student stu JOIN score s ON stu.no = s.s_no
-> WHERE s.score > 80;
```

no	name	score
S001	Sunny	98
S003	Kevin	88

2 rows in set (0.00 sec)

上面按语义的逻辑是：

- 第一步：先进行student和score的内连接，如下：

```
mysql> SELECT
-> stu.no, stu.name , s.score
-> FROM student stu JOIN score s ON stu.no = s.s_no ;
```

no	name	score
S001	Sunny	80
S001	Sunny	98
S001	Sunny	76
S003	Kevin	78
S003	Kevin	88
S003	Kevin	68

6 rows in set (0.00 sec)

- 第二步：对内联结果进行过滤， score > 80 得到，如下最终结果：

```

-> WHERE s.score > 80;
+-----+-----+-----+
| no    | name  | score |
+-----+-----+-----+
| S001  | Sunny | 98    |
| S003  | Kevin | 88    |
+-----+-----+-----+
2 rows in set (0.00 sec)

```

上面的查询过程符合语义，但是如果在filter条件能过滤很多数据的时候，先进行数据的过滤，在进行内联接会获取更好的性能，比如我们手工写一下：

```

mysql> SELECT
->   no, name , score
-> FROM student stu JOIN ( SELECT s_no, score FROM score s WHERE s.score > 80) s ON stu.s_no = s.s_no
+-----+-----+-----+
| no    | name  | score |
+-----+-----+-----+
| S001  | Sunny | 98    |
| S003  | Kevin | 88    |
+-----+-----+-----+
2 rows in set (0.00 sec)

```

上面写法语义和第一种写法语义一致，得到相同的查询结果，上面查询过程是：

- 第一步：执行过滤子查询

```

mysql> SELECT s_no, score FROM score s WHERE s.score >80;
+-----+-----+
| s_no | score |
+-----+-----+
| S001 | 98    |
| S003 | 88    |
+-----+-----+
2 rows in set (0.00 sec)

```

- 第二步：执行内连接


```

-> ON no = s_no;
+-----+-----+-----+
| no    | name  | score |
+-----+-----+-----+
| S001  | Sunny | 98    |
| S003  | Kevin | 88    |
+-----+-----+-----+
2 rows in set (0.00 sec)

```

如上两种写法在语义上一致，但在查询性能在数量很大的情况下会有很大差距。上面为了和大家演示相同的查询语义，可以有不同的查询方式，不同的执行计划。实际上数据库本身的优化器会帮我们做查询优化，在内联接中ON的联接条件和WHERE的过滤条件具有相同的优先级，具体的执行顺序可以由数据库的优化器根据性能消耗决定。也就是说物理执行计划可以先执行过滤条件进行查询优化，如果细心的读者可能发现，在第二个写法中，子查询我们不但有行的过滤，也进行了列的裁剪(去除了对查询结果没有用的c_no列)，这两个变化实际上对应了数据库中两个优化规则：

- filter push down
- project push down

OUTER JOIN

LEFT OUTER JOIN

左外联接语义是返回左表所有行，右表不存在补NULL，为了演示作用，我们查询没有参加考试的所有学生的成绩单：

```

mysql> SELECT
->   no, name , s.c_no, s.score
-> FROM student stu LEFT JOIN score s ON stu.no = s.s_no
-> WHERE s.score is NULL;
+-----+-----+-----+-----+
| no    | name  | c_no | score |
+-----+-----+-----+-----+
| S002  | Tom   | NULL | NULL  |
+-----+-----+-----+-----+
1 row in set (0.00 sec)

```

上面查询的执行逻辑上也是分成两步：

- 第一步：左外联接查询

```
mysql> SELECT
->   no, name , s.c_no, s.score
-> FROM student stu LEFT JOIN score s ON stu.no = s.s_no;
```

no	name	c_no	score
S001	Sunny	C01	80
S001	Sunny	C02	98
S001	Sunny	C03	76
S002	Tom	NULL	NULL
S003	Kevin	C01	78
S003	Kevin	C02	88
S003	Kevin	C03	68

-- 右表不存在的补NULL

```
7 rows in set (0.00 sec)
```

- 第二步：过滤查询

```
mysql> SELECT
->   no, name , s.c_no, s.score
-> FROM student stu LEFT JOIN score s ON stu.no = s.s_no
-> WHERE s.score is NULL;
```

no	name	c_no	score
S002	Tom	NULL	NULL

```
1 row in set (0.00 sec)
```

这个两个过程和上面分析的INNER JOIN一样，但是这时候能否利用上面说的 filter push down 的优化呢？根据LEFT OUTER JOIN的语义来讲，答案是否定的。我们手工操作看一下：

第一步：先进行过滤查询(获得一个空表)

```
mysql> SELECT * FROM score s WHERE s.score is NULL;
Empty set (0.00 sec)
```

第二步：进行左外链接

```
mysql> SELECT
->   no, name , s.c_no, s.score
-> FROM student stu LEFT JOIN (SELECT * FROM score s WHERE s.score is N

+-----+-----+-----+-----+
| no    | name  | c_no  | score |
+-----+-----+-----+-----+
| S001  | Sunny | NULL  | NULL  |
| S002  | Tom   | NULL  | NULL  |
| S003  | Kevin | NULL  | NULL  |
+-----+-----+-----+-----+
3 rows in set (0.00 sec)
```

我们发现两种写法的结果不一致，第一种写法只返回Tom没有参加考试，是我们预期的。第二种写法返回了Sunny，Tom和Kevin三名同学都没有参加考试，这明显是非预期的查询结果。所有LEFT OUTER JOIN不能利用INNER JOIN的 filter push down优化。

RIGHT OUTER JOIN

右外链接语义是返回右表所有行，左边不存在补NULL，如下：

```
mysql> SELECT
->   s.c_no, s.score, no, name
-> FROM score s RIGHT JOIN student stu ON stu.no = s.s_no;

+-----+-----+-----+-----+
| c_no  | score | no    | name  |
+-----+-----+-----+-----+
| C01   | 80    | S001  | Sunny |
| C02   | 98    | S001  | Sunny |
| C03   | 76    | S001  | Sunny |
| NULL  | NULL  | S002  | Tom   | -- 左边没有的进行补 NULL
| C01   | 78    | S003  | Kevin |
| C02   | 88    | S003  | Kevin |
| C03   | 68    | S003  | Kevin |
+-----+-----+-----+-----+
7 rows in set (0.00 sec)
```

上面右外链接我只是将上面左外链接查询的左右表交换了一下:.)。

FULL OUTER JOIN

全外链接语义返回左表和右表的并集，不存在一边补NULL,用于演示的MySQL数据库不支持

FULL OUTER JOIN。这里不做演示了。

SELF JOIN

上面介绍的INNER JOIN、OUTER JOIN都是不同表之间的联接查询，自联接是一张表以不同的别名做为左右两个表，可以进行如上的INNER JOIN和OUTER JOIN. 如下看一个INNER 自联接：

```
mysql> SELECT * FROM student l JOIN student r where l.no = r.no;
```

no	name	sex	no	name	sex
S001	Sunny	M	S001	Sunny	M
S002	Tom	F	S002	Tom	F
S003	Kevin	M	S003	Kevin	M

3 rows in set (0.00 sec)

不等值联接

这里说的不等值联接是SQL92语法里面的ON子句里面只有等值联接，比如：

```
mysql> SELECT
->     s.c_no, s.score, no, name
-> FROM score s RIGHT JOIN student stu ON stu.no != s.c_no;
```

c_no	score	no	name
C01	80	S001	Sunny
C01	80	S002	Tom
C01	80	S003	Kevin
C02	98	S001	Sunny
C02	98	S002	Tom
C02	98	S003	Kevin
C03	76	S001	Sunny
C03	76	S002	Tom
C03	76	S003	Kevin
C01	78	S001	Sunny
C01	78	S002	Tom
C01	78	S003	Kevin
C02	88	S001	Sunny
C02	88	S002	Tom
C02	88	S003	Kevin
C03	68	S001	Sunny
C03	68	S002	Tom
C03	68	S003	Kevin

18 rows in set (0.00 sec)

上面这示例，其实没有什么实际业务价值，在实际的使用场景中，不等值联接往往是结合等值联接，将不等值条件在WHERE子句指定，即，带有WHERE子句的等值联接。

Flink双流JOIN的支持

	CROSS JOIN	INNER JOIN	OUTER JOIN	SELF JOIN	ON(condition)	WHERE
Flink	N	Y	Y	Y	必选	可选

Flink目前支持INNER JOIN和LEFT OUTER JOIN（SELF可以转换为普通的INNER和OUTER）。在语义上面Flink严格遵守标准SQL的语义，与上面演示的语义一致。下面我重点介绍Flink中JOIN的实现原理。

双流JOIN与传统数据库表JOIN的区别

传统数据库表的JOIN是静态两张静态表的数据联接，在流上面是 动态表，双流JOIN的数据不断流入与传统数据库表的JOIN有如下3个核心区别：

- 左右两边的数据集合无穷 - 传统数据库左右两个表的数据集合是有限的，双流JOIN的数据会源源不断的流入；
- JOIN的结果不断产生/更新 - 传统数据库表JOIN是一次执行产生最终结果后退出，双流JOIN会持续不断的产生新的结果。
- 查询计算的双边驱动 - 双流JOIN由于左右两边的流的速度不一样，会导致左边数据到来的时候右边数据还没有到来，或者右边数据到来的时候左边数据没有到来，所以在实现中要将左右两边的流数据进行保存，以保证JOIN的语义。在Flink中会以State的方式进行数据的存储。

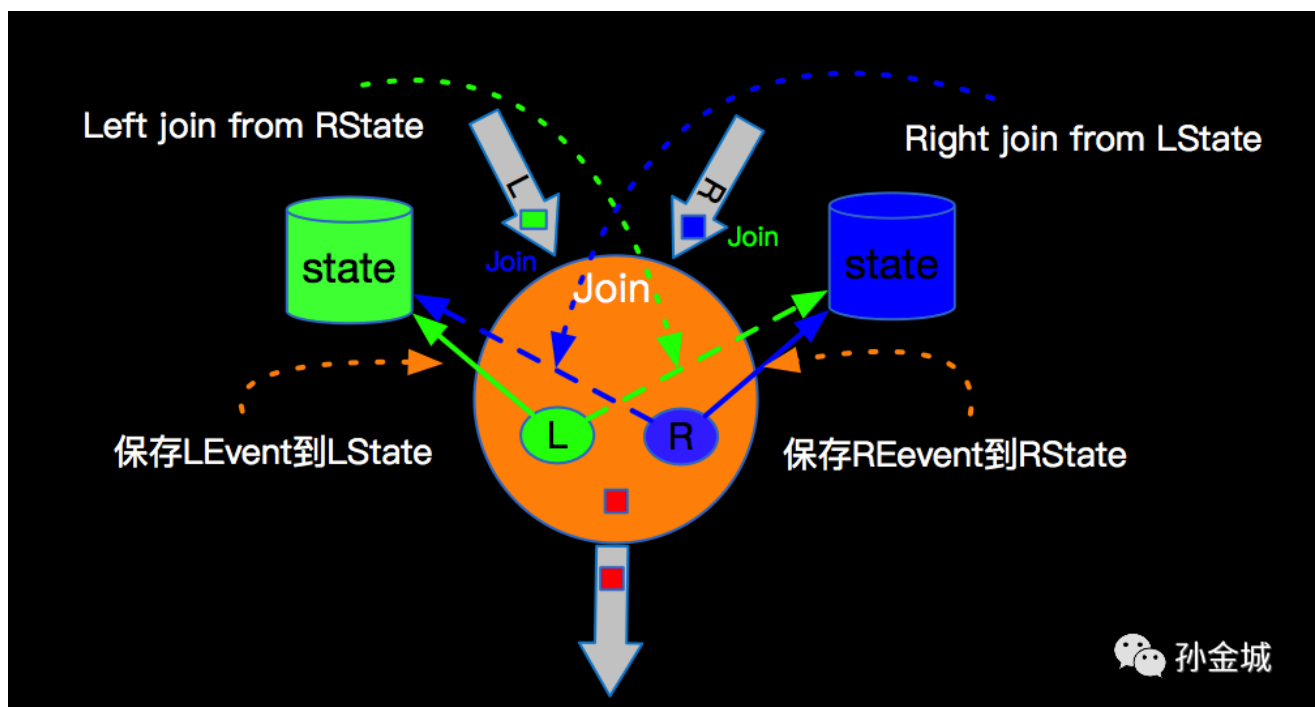
数据Shuffle

分布式流计算所有数据会进行Shuffle，怎么才能保障左右两边流的要JOIN的数据会在相同的节点进行处理呢？在双流JOIN的场景，我们会利用JOIN中ON的联接key进行partition，确保两个流相同的联接key会在同一个节点处理。

数据的保存

不论是INNER JOIN还是OUTER JOIN 都需要对左右两边的流的数据进行保存，JOIN算子会开辟左右两个State进行数据存储，左右两边的数据到来时候，进行如下操作：

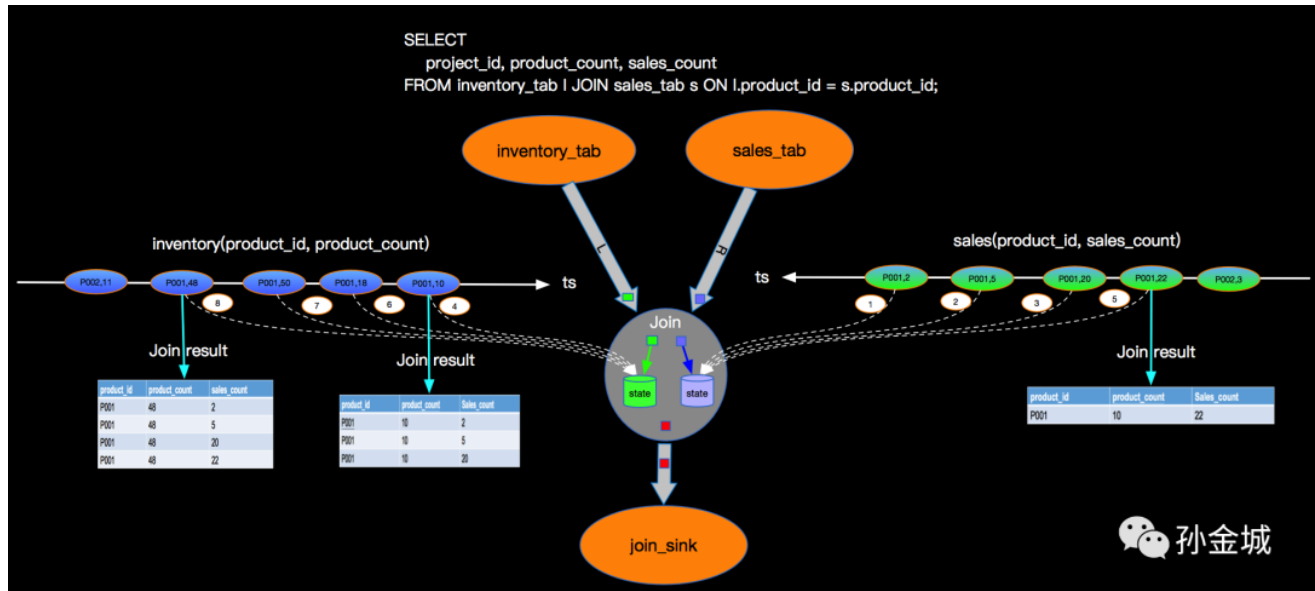
- LeftEvent到来存储到LState，RightEvent到来的时候存储到RState；
- LeftEvent会去RightState进行JOIN，并发出所有JOIN之后的Event到下游；
- RightEvent会去LeftState进行JOIN，并发出所有JOIN之后的Event到下游



简单场景介绍实现原理

INNER JOIN 实现

JOIN有很多复杂的场景，我们先以最简单的场景进行实现原理的介绍，比如：最直接的两个进行INNER JOIN，比如查询产品库存和订单数量，库存变化事件流和订单事件流进行INNER JOIN， JOIN条件是产品ID，具体如下：

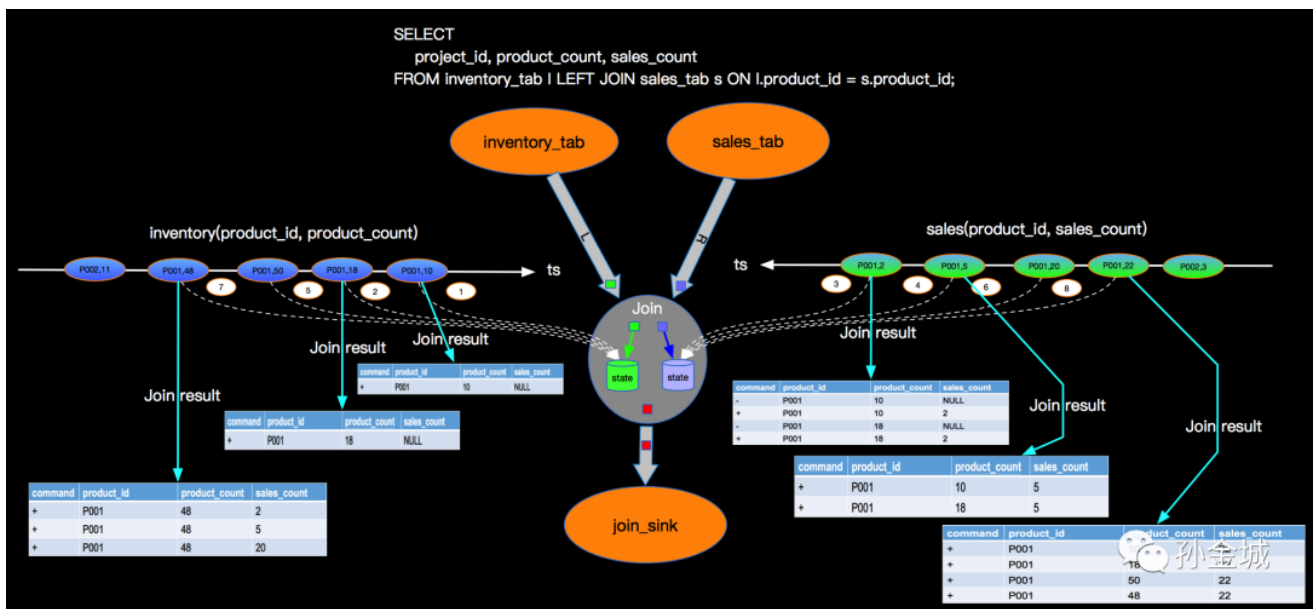


双流JOIN两边事件都会存储到State里面，如上，事件流按照标号先后流入到join节点，我们假设右边流比较快，先流入了3个事件，3个事件会存储到state中，但因为左边还没有数据，所有右边前3个事件流入时候，没有join结果流出，当左边第一个事件序号为4的流入时候，先存储左边state，再与右边已经流入的3个事件进行join，join的结果如图 三行结果会流入到下游节点sink。当第5号事件流入时候，也会和左边第4号事件进行join，流出一条join结果到下游节点。这里关于INNER JOIN的语义和大家强调两点：

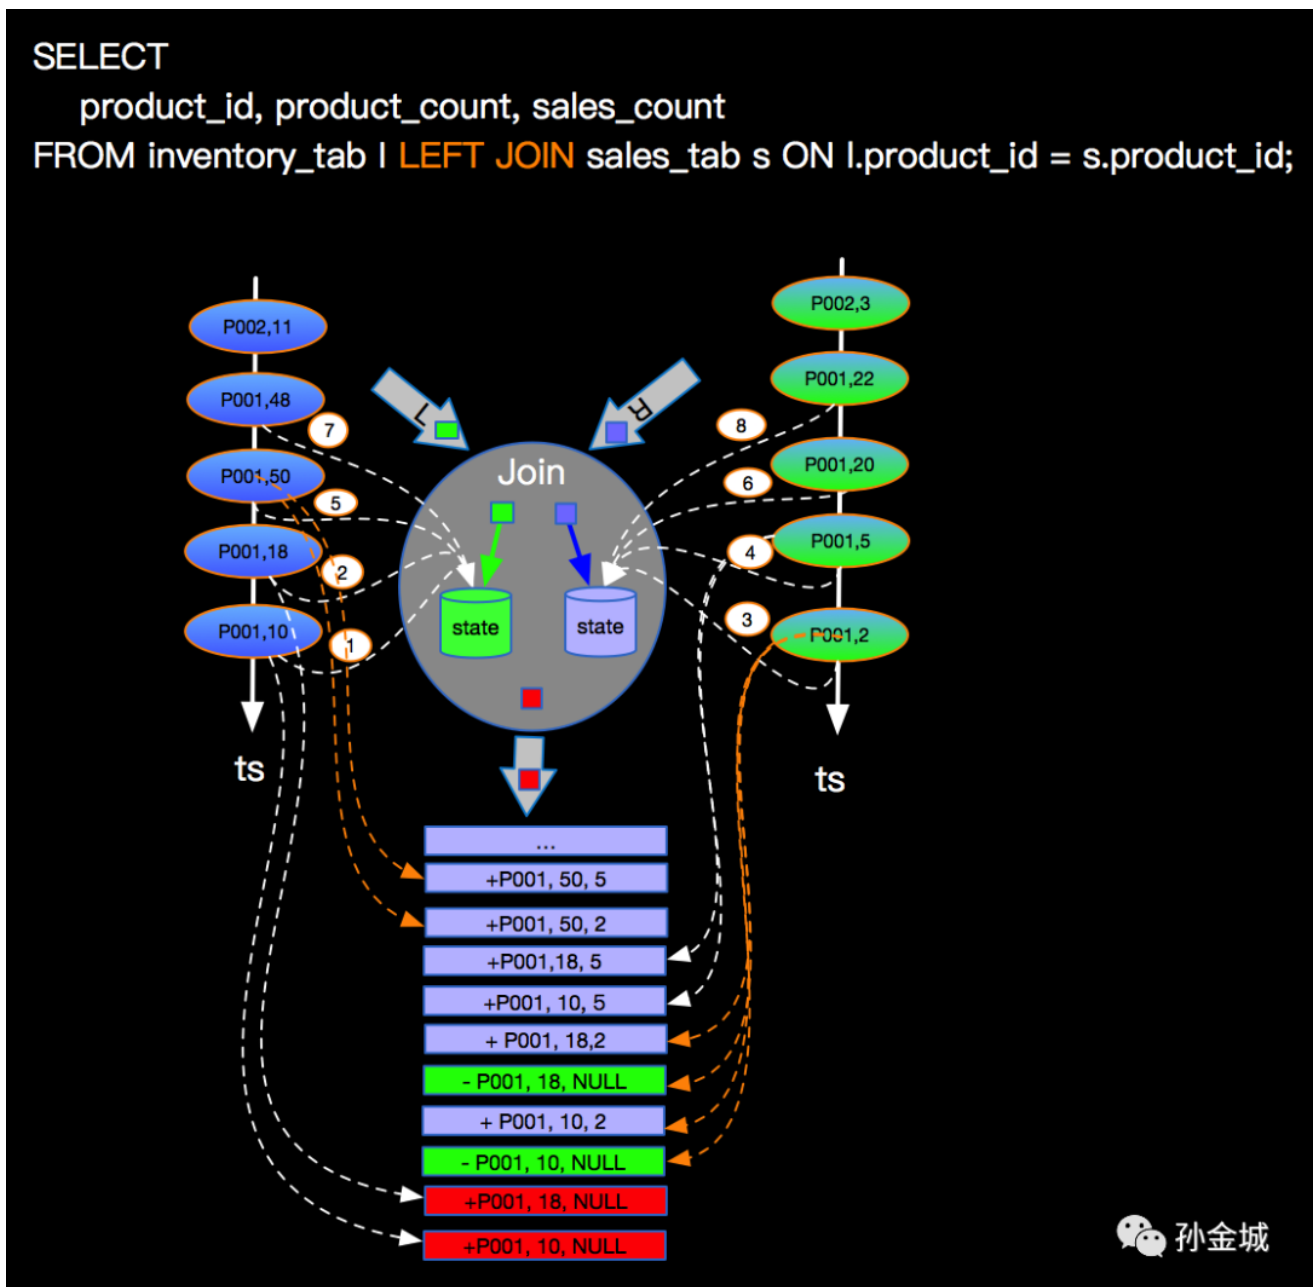
- INNER JOIN只有符合JOIN条件时候才会有JOIN结果流出到下游，比如右边最先来的1，2，3个事件，流入时候没有任何输出，因为左边还没有可以JOIN的事件；
- INNER JOIN两边的数据不论如何乱序，都能够保证和传统数据库语义一致，因为我们保存了左右两个流的所有事件到state中。

LEFT OUTER JOIN 实现

LEFT OUTER JOIN 可以简写 LEFT JOIN，语义上和INNER JOIN的区别是不论右流是否有JOIN的事件，左流的事件都需要流入下游节点，但右流没有可以JOIN的事件时候，右边的事件补NULL。同样我们以最简单的场景说明LEFT JOIN的实现，比如查询产品库存和订单数量，库存变化事件流和订单事件流进行LEFT JOIN， JOIN条件是产品ID，具体如下：



下图也是表达LEFT JOIN的语义，只是展现方式不同：



上图大主要关注点是当左边先流入1, 2事件时候，右边没有可以join的事件时候会向下游发送

左边事件并补NULL向下游发出，当右边第一个相同的Join key到来的时候会将左边先来的事件发出的带有NULL的事件撤回（对应上面command的-记录，+代表正向记录，-代表撤回记录）。这里强调三点：

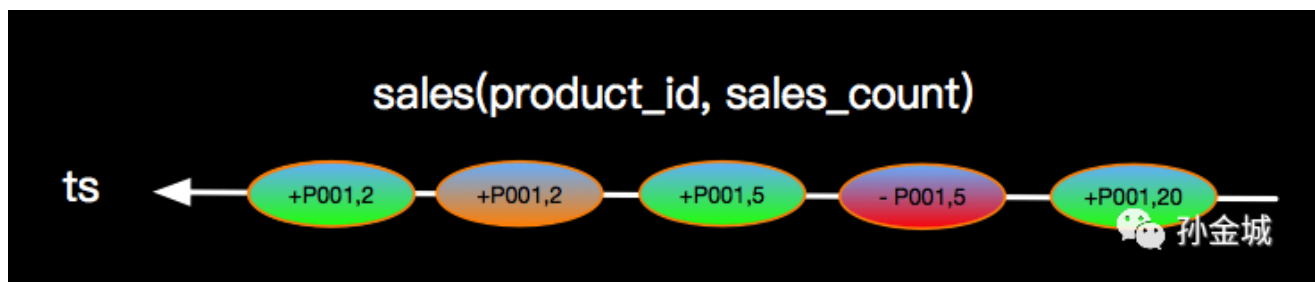
- 左流的事件当右边没有JOIN的事件时候，将右边事件列补NULL后流向下流；
- 当右边事件流入发现左边已经有可以JOIN的key的时候，并且是第一个可以JOIN上的右边事件（比如上面的3事件是第一个可以和左边JOIN key P001进行JOIN的事件）需要撤回左边下发的NULL记录，并下发JOIN完整（带有右边事件列）的事件到下游。后续来的4，5，6，8等待后续P001的事件是不会产生撤回记录的。
- 在Flink系统内部事件类型分为正向事件标记为“+”和撤回事件标记为“-”。

RIGHT OUTER JOIN 和 FULL OUTER JOIN

RIGHT JOIN内部实现与LEFT JOIN类似，FULL JOIN和LEFT JOIN的区别是左右两边都会产生补NULL和撤回的操作。对于State的使用都是相似的，这里不再重复说明了。

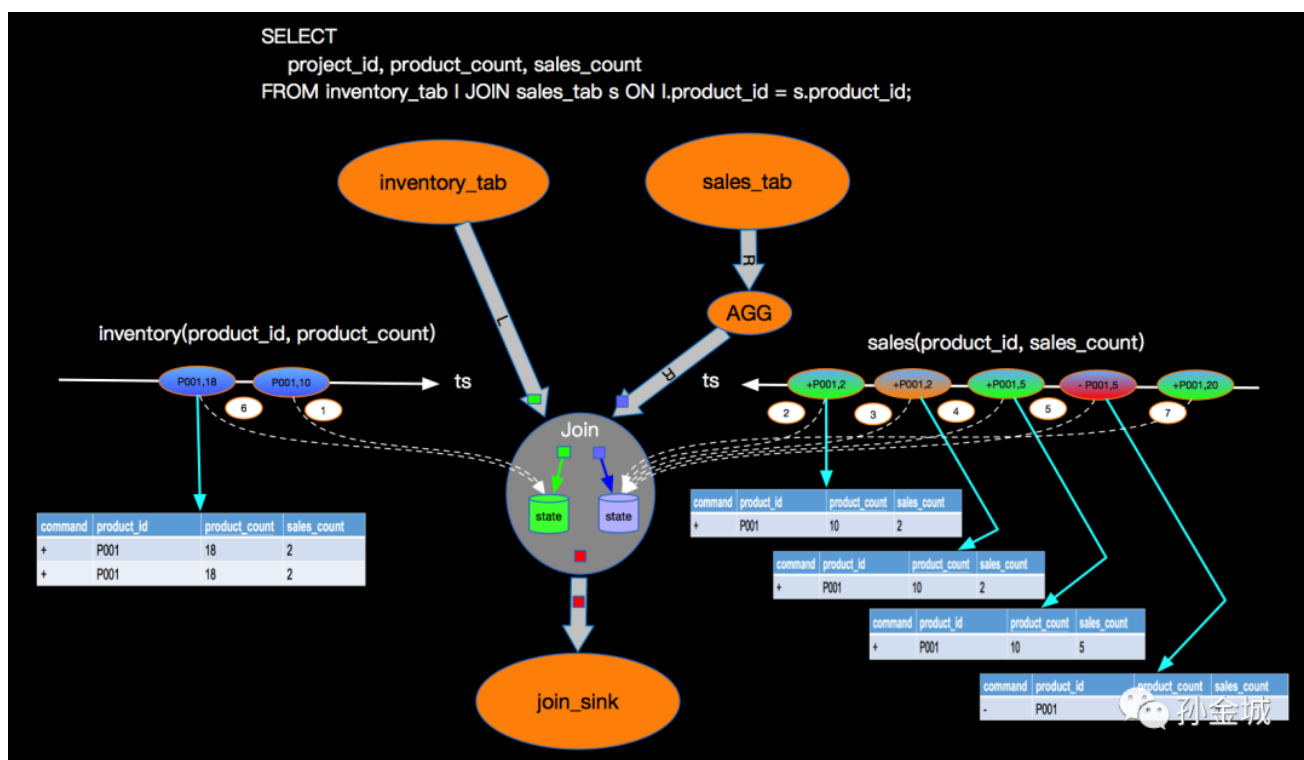
复杂场景介绍State结构

上面我们介绍了双流JOIN会使用State记录左右两边流的事件，同时我们示例数据的场景也是比较简单，比如流上没有更新事件（没有撤回事件），同时流上没有重复行事件。那么我们尝试思考下面的事件流在双流JOIN时候是怎么处理的？



上图示例是连续产生了2笔销售数量一样的订单，同时在产生一笔销售数量为5的订单之后，有将该订单取消了（或者退货了），这样在事件流上面就会是上图的示意，这种情况Flink内部如何支撑呢？

根据JOIN的语义以INNER JOIN为例，右边有两条相同的订单流入，我们就应该想下游输出两条JOIN结果，当有撤回的事件流入时候，我们也需要将已经下发下游的JOIN事件撤回，如下：



上面的场景以及LEFT JOIN部分介绍的撤回情况，需要Flink内部需要处理几个核心点：

- 记录重复记录（完整记录重复记录或者记录相同记录的个数）
- 记录正向记录和撤回记录（完整记录正向和撤回记录或者记录个数）
- 记录那一条事件是第一个可以与左边事件进行JOIN的事件

双流JOIN的State数据结构

在Flink内部对不同的场景有特殊的数据结构优化，本篇我们只针对上面说的情况（通用设计）介绍一下双流JOIN的State的数据结构和用途。

数据结构

- Map<JoinKey, Map<rowData, count>>
 - 第一级MAP的key是Join key，比如示例中的P001，value是流上面的所有完整事件
 - 第二级MAP的key是行数据，比如示例中的P001, 2，value是相同事件值的个数


数据结构的利用

- 记录重复记录 - 利用第二级MAP的value记录重复记录的个数，这样大大减少存储和读取
- 正向记录和撤回记录 - 利用第二级MAP的value记录，当count=0时候删除改元素
- 判断右边是否产生撤回记录 - 根据第一级MAP的value的size来判断是否产生撤回，只有size由0变成1的时候（第一条和左可以JOIN的事件）才产生撤回

双流JOIN的应用优化


NULL造成的热点

比如我们有A LEFT JOIN B ON A.aCol = B.bCol LEFT JOIN C ON B.cCol = C.cCol 的业务，JOB的DAG如下：



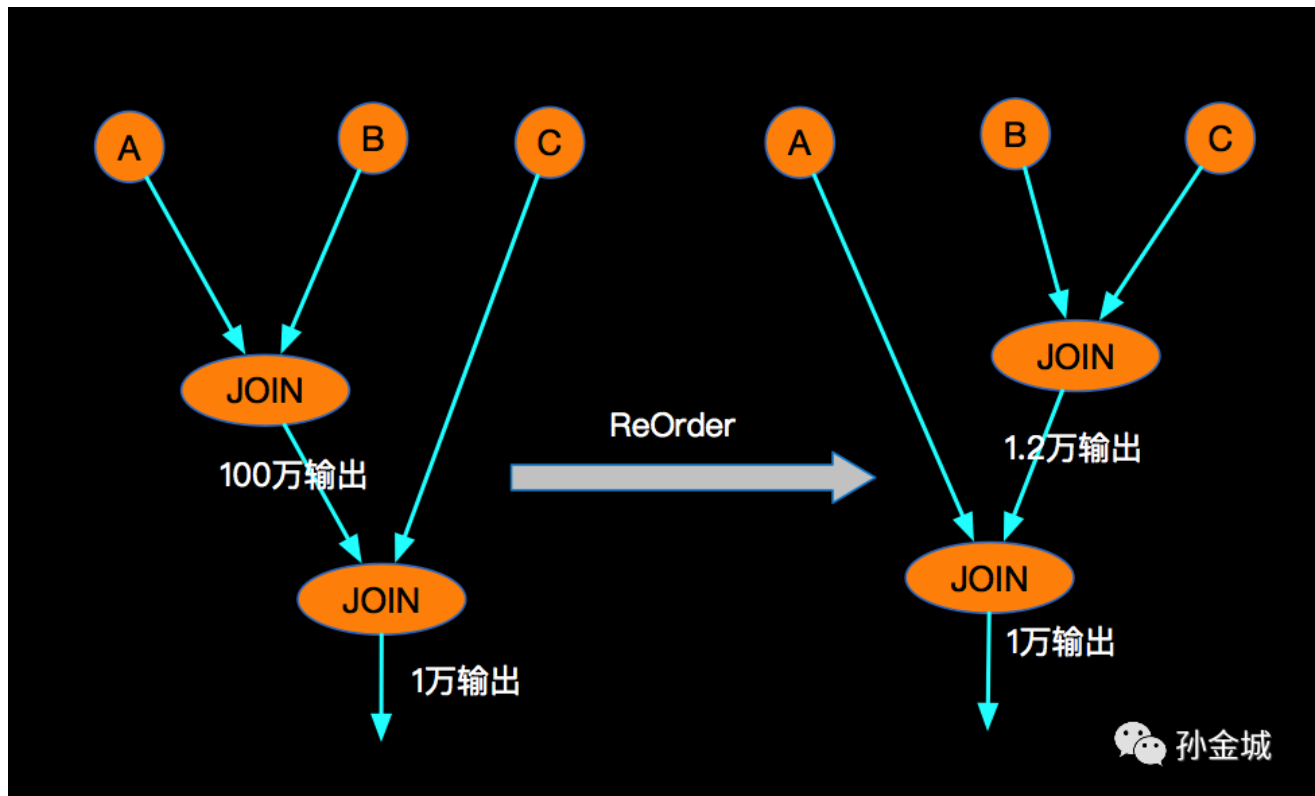
假设在实际业务中有这这样的特点，大部分时候当A事件流入的时候，B还没有可以JOIN的数据，但是B来的时候，A已经有可以JOIN的数据了，这特点就会导致，A LEFT JOIN B 会产生大量的 (A, NULL),其中包括B里面的 cCol 列也是NULL，这时候当与C进行LEFT JOIN的时候，首先Flink内部会利用cCol对AB的JOIN产生的事件流进行Shuffle， cCol是NULL进而是下游节点大量的NULL事件流入，造成热点。那么这问题如何解决呢？

我们可以改变JOIN的先后顺序，来保证A LEFT JOIN B 不会产生NULL的热点问题，如下：



JOIN ReOrder

对于JOIN算子的实现我们知道左右两边的事件都会存储到State中，在流入事件时候在从另一边读取所有事件进行JOIN计算，这样的实现逻辑在数据量很大的场景会有一定的state操作瓶颈，我们某些场景可以通过业务角度调整JOIN的顺序，来消除性能呢瓶颈，比如：A JOIN B ON A.acol = B.bcol JOIN C ON B.bcol = C.ccol. 这样的场景，如果 A与B进行JOIN产生数据量很大，但是B与C进行JOIN产生的数据量很小，那么我们可以强制调整JOIN的联接顺序，B JOIN C ON b.bcol = c.ccol JOIN A ON a.acol = b.bcol. 如下示意图：



小结

本篇初步向大家介绍传统数据库的JOIN的类型，语义和可以使用的查询优化，再以实际的例子介绍Flink上面的双流JOIN的实现和State数据结构设计，最后向大家介绍双流JOIN的使用优化。本篇只介绍了等值JOIN(ON 子句只有等值条件)，Flink目前也支持非等值联接条件和等值联接条件相结合使用，本质是相当于添加了WHERE子句。