Flink事件时间何时触发窗口计算

目录

1.1 浏览本博客前你需要了解的知识点

flink内部是如何划分窗口的?

触发的条件?

何时第一次触发?

1.2 示例: 触发窗口计算

第一次触发计算

何时第二次触发计算

何时触发多个窗口计算?

思考:

什么时候才会触发窗口计算?

既然使用的是事件时间那么必然会涉及到水位线(water_mark),水位线在其中扮演的角色是什么? 此时我们带着疑问,一步一步的探究

注意:

- 1、本篇博客中的所有解释都是在滚动窗口的前提下
- 2、浏览本博客前观看本栏另外一篇博客"Flink时间概念与水位线"尤佳。

Q: 为什么要在滚动窗口的前提下进行解释?

A: 因为滚动窗口相比较滑动和会话来说更容易让大家理解,在本篇博客中着重的是讨论 水位线在窗口触发下的场景,因此当然采用大家较容易理解的窗口来为大家解释。

Q: 那我要是想了解水位线在其他窗口下的场景呢?

A: 在本栏的其他博客有详细介绍。

1.1 浏览本博客前你需要了解的知识点

flink内部是如何划分窗口的?

首先Windows的时间范围是一个自然时间范围,比如你定义了一个窗口: timeWindow(Time.seconds(3));那么其windows会将窗口中的事件按照3S进行划分(左闭右开)

> [10:11:00,10:11:03) [10:11:03,10:11:06)

... ... [10:11:21,10:11:24)

... ...

当一个Event Time = 10:11:22的记录到来时就会生成如下窗口,此时这条消息就存放在这个窗口中; [10:11:21,10:11:24]

触发的条件?

- a、water_mark时间 >= window_end_time只是第一个条件
- b、在[window_start_time,window_end_time)区间中还需要有数据存在,如果没有数据同样是不会触发的。

何时第一次触发?

当water_marker >= windows_end_time窗口结束时间,就会触发窗口操作。

(最新的water_marker时间戳会在过去的windows_end_time窗口结束时间中逐一进行比较,如果发现有 >= 的情况就会触发窗口操作)

1.2 示例: 触发窗口计算

示例 最大乱序事件10秒,窗口时间3秒

第一次触发计算

```
输入数据:
1,1538359882000
2,1538359886000
3,1538359892000
4,1538359893000
5,1538359894000
```

定义下方输出数据中的water_mark

```
val watermark: DataStream[(String, Long, String, Int)] = inputMap.assi
2
     gnTimestampsAndWatermarks(new AssignerWithPeriodicWatermarks[(String, Lo
3
     ng, String, Int)] {
4
         val maxOutOfOrderness = 10000L //最大允许的乱序时间是10s
 5
         var currentMaxTimestamp = 0L
 6
         var a: Watermark = _
8
         override def getCurrentWatermark: Watermark = {
9
           a = new Watermark(currentMaxTimestamp - maxOutOfOrderness)
10
11
```

```
12
13
14
         override def extractTimestamp(element: (String, Long, String, Int),
15
     previousElementTimestamp: Long): Long = {
16
           val timestamp = element._2
           currentMaxTimestamp = Math.max(timestamp, currentMaxTimestamp)
17
18
           val end = if (!a.toString.contains("-")) {
19
             val regEx = "[^0-9]";
20
             val p = Pattern.compile(regEx);
21
             val m = p.matcher(a.toString);
22
             val L_number = m.replaceAll("").trim()
23
             format.format(L number.toLong)
24
           } else a.toString
           println("timestamp:" + element._1 + "," + element._2 + "," + eleme
25
26
     nt._3 + "|" +
27
             s"${a.toString}($end)" + "|" + format.format(currentMaxTimestamp
28
      - maxOutOfOrderness))
29
           val lll: Long = System.currentTimeMillis()
           timestamp
```

当我们依次输入数据的时候,在输入完 5,1538359894000 这条数据后,最新的water_marker是: 10:11:23。由于该条记录的水位线为: 10:11:24 > 10:11:23,因此水位线会进行更新,变成10:11:24,而10:11:24 >= window end time(10:11:24),所以此时就会触发计算操作。

此时的触发操作计算的是event_time(事件时间)在[10:11:21,10:11:24)窗口之间的数据(也就是只会计算 1,1538359882000 这一条数据)

```
输出数据为:
当前数据 | 当前数据的水位线,计算并更新水位线
timestamp: 1,1538359882000 ,10:11:22|Watermark@-10000(Watermark@-0000),10:11:12
timestamp: 2,1538359886000 ,10:11:26|Watermark@1538359872000(10:11:12),10:11:16
timestamp: 3,1538359892000 ,10:11:32|Watermark@1538359876000(10:11:16),10:11:22
timestamp: 4,1538359893000 ,10:11:33|Watermark@1538359882000(10:11:22), 10:11:23
timestamp: 5,1538359894000 ,10:11:34|Watermark@1538359883000(10:11:23), 10:11:24
第一次触发计算: (1,1538359882000, 10:11:22,1)
```

何时第二次触发计算

```
输入数据:
```

```
2,1538359886000
3,1538359892000
4,1538359893000
5,1538359894000
6,1538359896000
7,1538359897000
```

输出数据为:

timestamp:1,1538359882000,10:11:22|Watermark@-10000(Watermark@-0000),10:11:12 timestamp:2,1538359886000,10:11:26|Watermark@1538359872000(10:11:12),10:11:16 timestamp:3,1538359892000,10:11:32|Watermark@1538359876000(10:11:16),10:11:22 timestamp:4,1538359893000,10:11:33|Watermark@1538359882000(10:11:22), 10:11:23 timestamp:5,1538359894000,10:11:34|Watermark@1538359883000(10:11:23), 10:11:24 第一次触发计算: > (1,1538359882000, 10:11:22,1) timestamp: 6,1538359896000,10:11:36|Watermark@1538359884000(10:11:24),10:11:26

timestamp: 7, 1538359897000, 10:11:37|Watermark@1538359886000(10:11:26), 10:11:27

第二次触发计算: > (2,1538359886000, 10:11:26,1)

第一次的窗口[10:11:21,10:11:24)已经被使用了,那么程序下次触发的窗口则是 [10:11:24,10:11:27),因此我输入的 7,1538359897000 这条数据,而该条数据中的 water mark则会更新成10:11:27而10:11:27 >= window end time(10:11:27), 因此会触 发操作。

(此时计算的是[10:11:24,10:11:27)窗口内的数据,在上面的输入数据中只有2,1538359886000这条 数据属于这个窗口,因此计算的是该条数据)

何时触发多个窗口计算?

输入数据:

1,1538359882000

2,1538359886000

3,1538359892000

4,1538359893000

5,1538359894000

6,1538359907000

输出数据:

timestamp:1,1538359882000,10:11:22|Watermark@-10000(Watermark@-0000),10:11:12 timestamp:2,1538359886000,10:11:26|Watermark@1538359872000(10:11:12),10:11:16 timestamp:3,1538359892000,10:11:32|Watermark@1538359876000(10:11:16),10:11:22 timestamp:4,1538359893000,10:11:33|Watermark@1538359882000(10:11:22), 10:11:23 timestamp:5,1538359894000,10:11:34|Watermark@1538359883000(10:11:23), 10:11:24 第一次触发计算: > (1,1538359882000, 10:11:22,1)

timestamp: 6, 1538359907000, 10:11:47|Watermark@1538359884000(10:11:24), 10:11:37

触发计算: > (2,1538359886000, 10:11:26,1) 触发计算: > (3,1538359892000, 10:11:32,1) 触发计算: > (4,1538359893000, 10:11:33,1) 触发计算: > (5,1538359894000, 10:11:34,1)

> [10:11:21,10:11:24)已经在第一次进行触发了 [10:11:24,10:11:27) [10:11:27,10:11:31) [10:11:31,10:11:34) [10:11:34,10:11:37)

...

由于timestamp 2,3,4,5的event_time 分别在这些窗口之间,因此输出的话就会在这次触发操作中全部进行输出了;计算的是每个窗口内的数据。